PharmaNLU-A — poser une question, obtenir la requête SPARQL

Modèle de traitement du langage naturel développé par l'équipe NeoCoders (Chemlali Ismail) · 100 % local · aucune API de LLM

À quoi sert le modèle ? L'utilisateur tape une question en français dans la page **Assistant IA**, sans connaître SPARQL. Le modèle comprend ce qu'il demande, reconnaît les médicaments, molécules et maladies cités, **écrit la requête SPARQL**, l'exécute sur l'ontologie et répond par une phrase, un tableau de résultats et la requête générée. Il remplace la console SPARQL pour un utilisateur non spécialiste.

Question	→ 1. Normaliser	→ 2. Reconnaître	→ 3. Comprendre	→ 4. Traduire	→ Réponse
texte libre en français, fautes acceptées	spaCy : tokens, lemmes, sans accents	EntityRuler + RapidFuzz : médicaments, molécules, maladies	scikit-learn : laquelle des 12 intentions ?	gabarit SPARQL rempli avec les URI	phrase + tableau + requête affichée

1 Ce que l'on peut demander : 12 types de questions (intentions)

Intention	Exemple de question	Ce que fait la requête générée
Lister une classe	« Liste des antibiotiques »	molécules de la classe, sous-classes incluses (inférence)
Filtrer les médicaments	« Sans ordonnance à moins de 5 dinars »	filtres prix / ordonnance / type / forme ; « le plus cher »
Médicaments contenant	« Quels médicaments contiennent de l'ibuprofène ? »	propriété inverse estContenuDans
Composition	« Que contient le Doliprane ? »	molécules du médicament
Effets secondaires	« Effets graves de l'Advil »	chemin médicament → molécule → effet, filtre gravité
Contre-indications	« Contre-indications de l'aspirine »	chemin molécule → contre-indication → pathologie
À éviter si maladie	« Quels médicaments éviter en cas d'ulcère ? »	propriété estContreIndiquePour déduite par la chaîne OWL
Générique moins cher	« Un générique moins cher que le Clamoxyl ? »	même composition + économie calculée (BIND)
Interactions	« Advil et Aspégic interagissent-ils ? »	propriété symétrique interagitAvec
Attribut	« Code ATC du paracétamol » · « Prix du Zithromax »	lecture d'une donnée ; « sur ordonnance ? » → requête ASK
Indication	« Que prendre contre la migraine ? »	médicaments indiqués, sauf ceux contre-indiqués
Statistiques	« Combien de médicaments génériques ? »	COUNT, AVG, MIN, MAX

2 Exemple pas à pas : « Quels médicaments contiennent de l'ibuprophène ? » (faute volontaire)

Normalisation	quels medicaments contiennent de l' ibuprophene — lemmes : contiennent → contenir
Entités	« ibuprophene » n'existe pas dans l'ontologie → RapidFuzz trouve **Ibuprofène** (similarité 86 %, badge « corrigé »)
Délexicalisation	quel medicament contenir de le **xmol** — le nom est remplacé par son type : le modèle apprend la forme de la question
Intention	**medicaments_contenant**, confiance 97 % (2e hypothèse affichée si elle dépasse 8 %)
Requête	SELECT ?medicament ?label ?prix WHERE { :Ibuprofene :estContenuDans ?medicament . … } ORDER BY ?prix
Réponse	« Ibuprofène se trouve dans : Ibuprofène Mylan 400 mg et Advil 400 mg. » + tableau exportable en CSV

3 Fonctionnalités qui le rendent fiable

Tolère les fautes	« dolipran », « amoxiciline », « zitromax », « advill » sont corrigés automatiquement (RapidFuzz).
Synonymes métier	« antidouleur » → Antalgique, « mal de tête » → Migraine, « problème de reins » → Insuffisance rénale…
Apprend les nouvelles données	Le dictionnaire est relu dans l'ontologie : un médicament créé via le CRUD est reconnu tout de suite, sans ré-entraînement.
Ne devine jamais	Confiance < 40 % → « je n'ai pas compris » + exemples ; entité manquante → « Précisez le médicament… ».
Requête toujours valide	La requête vient d'un gabarit écrit à la main, pas d'un texte généré : pas d'erreur de syntaxe possible.
Explicable	Intention, confiance, entités, filtres, étapes et requête commentée sont affichés ; historique et suggestions cliquables.

4 Comment il a été construit et évalué

96,9 %	100 %	314 / 96	253 Ko
questions de test bien comprises (93 / 96)	entités reconnues sur le test	questions d'entraînement / de test	taille du modèle, commité dans Git

Bibliothèques : spaCy 3.8 + fr_core_news_sm (tokenisation, lemmes, EntityRuler) · scikit-learn 1.9 (TF-IDF mots 1–2-grammes et caractères 3–5-grammes → régression logistique) · RapidFuzz 3.14 (distance de Levenshtein) · rdflib 7.6 (exécution SPARQL). **Données :** questions d'entraînement issues de gabarits écrits à la main ; jeu de test écrit séparément, avec d'autres formulations et des fautes. **Reproductible :** graine 42, **python -m nlp.train** ré-entraîne et réécrit la carte du modèle, 16 tests automatiques.